FinComercial, S.A.

Analítica inteligente para anticipar el riesgo

REPORTE TÉCNICO · ACTIVIDAD 6

FinPredict

Evaluación, validación y ajuste operativo de modelos para riesgo hipotecario

Propósito del documento

Evaluar la capacidad predictiva de FinPredict mediante baseline, validación cruzada temporal, comparación estadística, ajuste de threshold, holdout independiente y una simulación A/B; traduciendo las métricas técnicas a una decisión operativa y de negocio.

CAMPO	INFORMACIÓN
Organización	FinComercial, S.A.
Responsable	Lizbeth Bruno Lorenzana · AI Lead
Asignatura	Gestión de Proyectos de Inteligencia Artificial
Fecha	25/10/2026
Versión	1.0 · Cierre analítico Actividad 6

Repositorio técnico: github.com/lizlorenzana931109-art/FinPredict-Actividad6

1. Resumen ejecutivo

Síntesis de desempeño, decisión de modelo y lectura operativa.

303,234	33,603	0.9248	0.3469
observaciones de desarrollo	observaciones holdout	ROC-AUC final	PR-AUC final

DIMENSIÓN	RESULTADO / LECTURA EJECUTIVA
Problema	Anticipar incumplimiento hipotecario de 90 días para priorizar acciones preventivas.
Población	Créditos con 0-60 días de atraso; 61-89 días pasan a cobranza intensiva y >=90 quedan fuera del modelo predictivo.
Modelo final	Regresión Logística; ventaja estadísticamente consistente en PR-AUC frente a Random Forest.
Threshold	0.75; prioriza 11.10% del holdout y conserva recall de 75.64%.
Holdout	950 verdaderos positivos, 306 falsos negativos, 2,780 falsos positivos y 29,567 verdaderos negativos.
A/B simulado	Reducción relativa de incumplimiento de 20.95% bajo supuesto académico de efectividad del 15%.

Decisión ejecutiva | GO condicionado para piloto controlado

La evidencia sintética respalda continuar con una validación piloto y no una automatización de decisiones adversas. El valor del modelo está en priorizar una fracción reducida de la cartera con alta concentración de riesgo, manteniendo supervisión humana, límites de capacidad operativa y medición prospectiva de impacto.

2. Problema, datos y protocolo experimental

Diseño temporal para minimizar fuga de información y separar selección de evaluación final.

OBJETIVO DEL MODELO

Estimar la probabilidad de que un crédito alcance incumplimiento de 90 días durante el trimestre posterior al corte. FinPredict funciona como mecanismo de priorización preventiva; no modifica contratos ni determina decisiones crediticias automáticas.

COMPONENTE	EVIDENCIA DOCUMENTADA
Desarrollo	303,234 observaciones; 42,036 créditos; 11,642 positivos (3.84%).
Holdout	33,603 observaciones; 1,256 positivos (3.74%); corte 30/09/2025, horizonte 2025-T4.
Predictores	15 variables financieras, de mora y comportamiento transaccional.
Modelos	DummyClassifier, Regresión Logística y Random Forest.
Validación	Tres folds temporales expansivos; predicciones OOF para comparación estadística.
Selección	PR-AUC como métrica principal por desbalance; ROC-AUC, recall, precision, specificity y F1 como soporte.

BASELINE: POR QUÉ ACCURACY NO ES SUFICIENTE

96.16%	0%	0%	0.5000
Accuracy	Precision	Recall	ROC-AUC

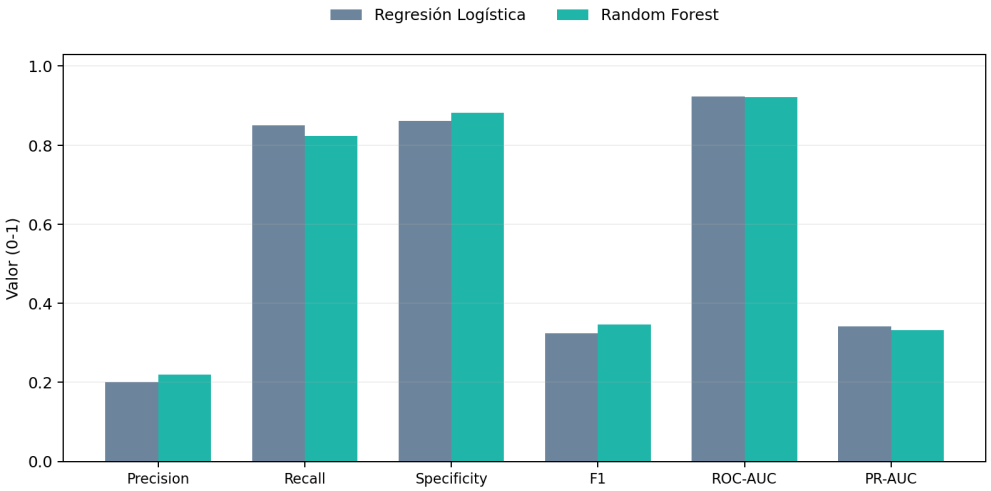
Lectura del baseline

DummyClassifier predice siempre la clase mayoritaria y alcanza 96.16% de accuracy, pero no identifica ningún incumplimiento. Este resultado demuestra que la evaluación debe centrarse en la clase minoritaria y justifica priorizar PR-AUC, recall y F1 sobre accuracy aislada.

3. Comparación de modelos y evidencia estadística

Validación cruzada temporal y bootstrap agrupado por crédito.

MÉTRICA	LOGÍSTICA	RANDOM FOREST	LECTURA
Precision	0.2003	0.2199	RF +0.0196
Recall	0.8509	0.8228	Logística +0.0281
Specificity	0.8617	0.8811	RF +0.0194
F1	0.3241	0.3468	RF +0.0227
ROC-AUC	0.9227	0.9219	Prácticamente empate
PR-AUC	0.3409	0.3318	Logística +0.0091



BOOTSTRAP AGRUPADO POR CRÉDITO

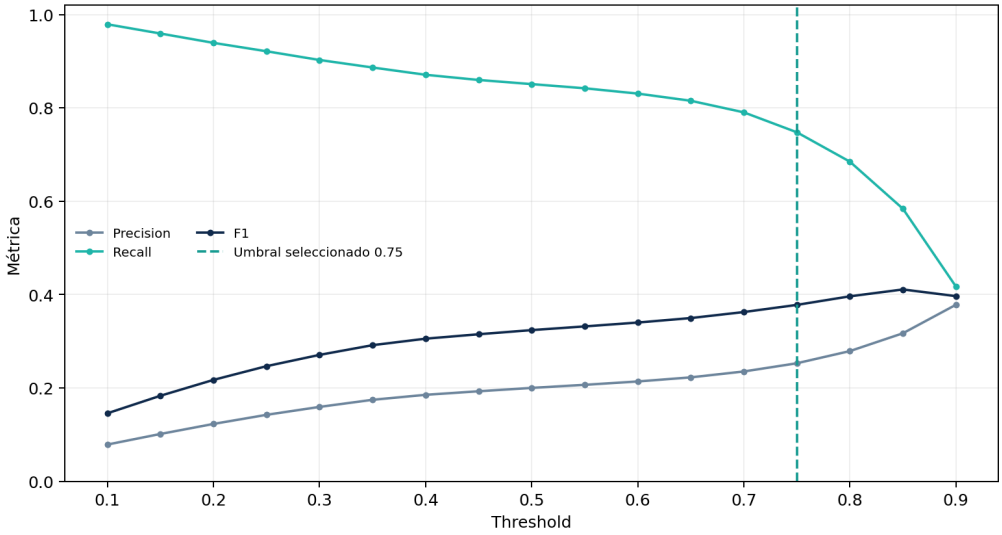
MÉTRICA	DIFERENCIA	IC 95%	INTERPRETACIÓN
PR-AUC	+0.0104	0.0039 a 0.0174	IC 95% no incluye 0; ventaja consistente para Logística.
ROC-AUC	+0.0008	-0.0003 a 0.0018	IC 95% incluye 0; no hay superioridad concluyente.

Decisión de modelo

Se selecciona Regresión Logística porque la ventaja en PR-AUC es consistente y, en un problema con prevalencia cercana al 4%, esta métrica es más informativa sobre la calidad de la clase positiva. La selección también favorece interpretabilidad y simplicidad operativa.

4. Threshold operativo y matriz de confusión

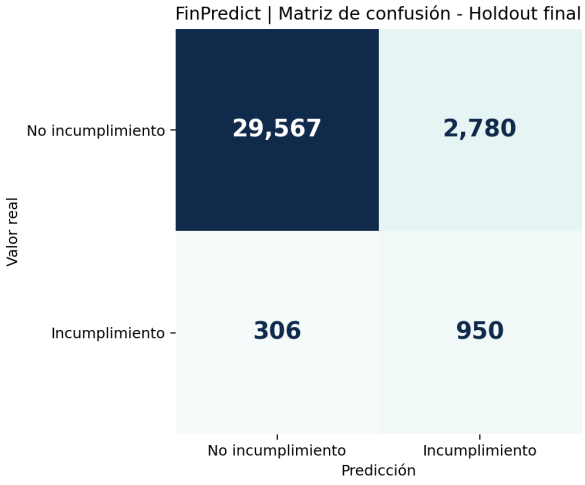
Selección del punto de corte antes de abrir el holdout final.



THRESHOLD	PRECISION	RECALL	F1	CARTERA PRIORIZADA
0.50	20.00%	85.11%	32.39%	16.61%
0.75	25.28%	74.79%	37.79%	11.54%
0.85	31.71%	58.40%	41.10%	7.19%

Criterio operativo | threshold 0.75

Aunque 0.85 maximiza F1, reduce el recall a 58.40%. El umbral 0.75 mantiene detección de aproximadamente tres cuartas partes de los incumplimientos y limita la cartera priorizada a cerca de 11%, mejorando el equilibrio entre prevención y capacidad de atención.



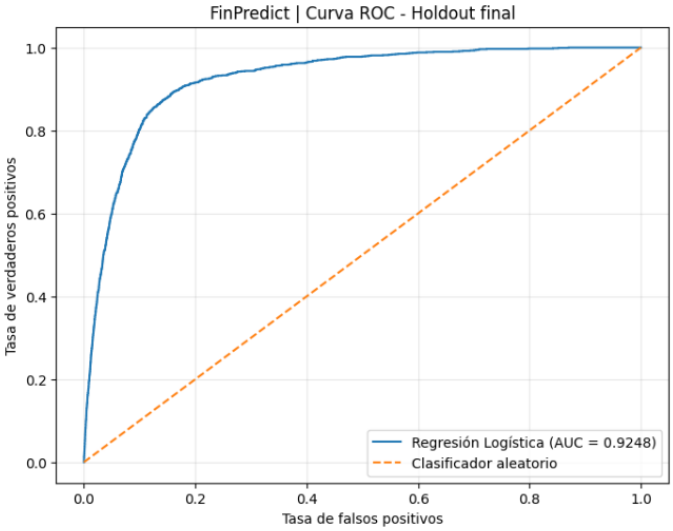
TIPO	N	SIGNIFICADO
Verdaderos positivos	950	Incumplimientos detectados
Falsos negativos	306	Casos de riesgo sin alerta preventiva.
Falsos positivos	2,780	Contactos/revisiones innecesarias.
Verdaderos negativos	29,567	Créditos sin evento clasificados

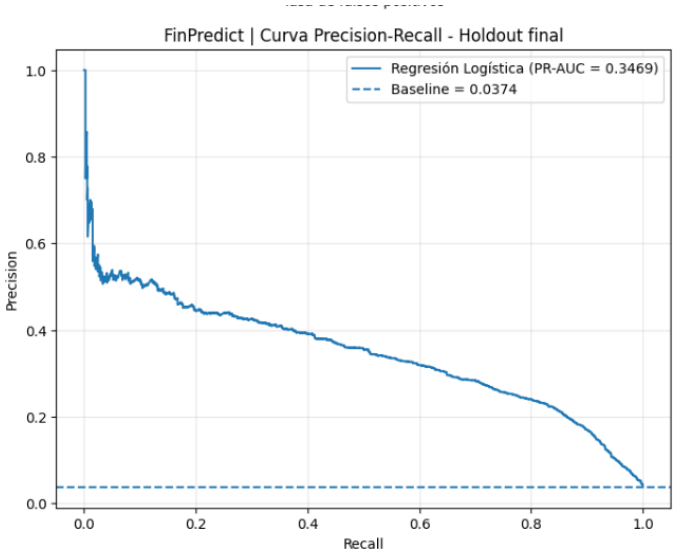
5. Evaluación final en holdout

Desempeño sobre datos no utilizados para selección de modelo ni threshold.

25.47%	75.64%	91.41%	38.11%
Precision	Recall	Specificity	F1-score

CURVAS DE DISCRIMINACIÓN





INDICADOR	RESULTADO	LECTURA
ROC-AUC	0.9248	Alta capacidad de ordenamiento global entre positivos y negativos.
PR-AUC	0.3469	Muy superior al baseline de prevalencia 0.0374; métrica prioritaria por desbalance.
Cartera priorizada	11.10%	3,730 de 33,603 créditos reciben alerta con threshold 0.75.

Generalización temporal

El comportamiento del holdout es coherente con las predicciones OOF: precision 25.47% vs 25.28%, recall 75.64% vs 74.79% y F1 38.11% vs 37.79%. La ausencia de una caída relevante respalda estabilidad descriptiva, sin equivaler a validez externa sobre cartera real.

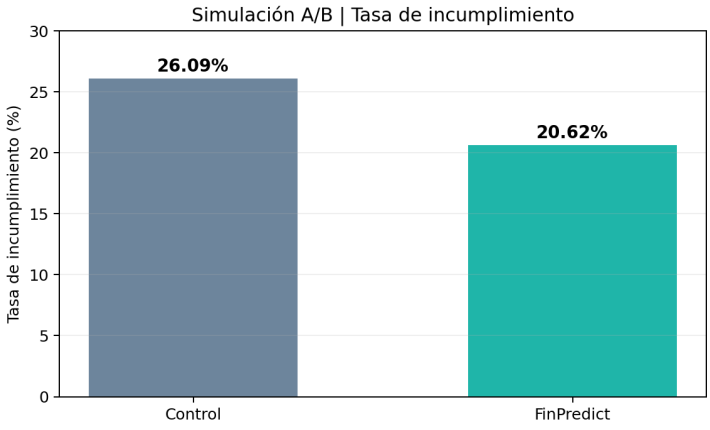
6. Prueba A/B simulada e impacto de negocio

Diseño académico para distinguir validación predictiva de evaluación causal.

MÉTODO	PREGUNTA QUE RESPONDE	EVIDENCIA
Validación cruzada	¿El modelo generaliza entre periodos históricos?	Métricas predictivas en folds temporales.
Prueba A/B	¿Una intervención basada en el modelo cambia un resultado operativo?	Comparación aleatoria entre control y tratamiento.

Supuesto de simulación

Sobre los 3,730 créditos priorizados se asignan grupos Control y FinPredict. La intervención preventiva del grupo tratado se simula con una efectividad del 15%. El ejercicio ilustra el método; no representa evidencia causal real ni resultado productivo.



GRUPO	CRÉDITOS	INCUMPL.	TAS
Control	1,863	486	26.09%
FinPredict	1,867	385	20.62%

INDICADOR	RESULTADO
Reducción absoluta	5.47 pp
Reducción relativa	20.95%
NNT	18.3
Incumplimientos evitados estimados	102
Chi-cuadrada / p-value	15.2599 / 0.0001

Lectura de negocio

Bajo el escenario simulado, sería necesario intervenir aproximadamente 18 créditos para evitar un incumplimiento adicional. El p-value describe diferencia estadística dentro de la simulación, pero no demuestra efectividad real porque el efecto fue impuesto como supuesto. El siguiente paso empresarial correcto es un piloto controlado con outcome medido prospectivamente.

7. Conclusiones, trazabilidad y siguiente decisión

Cierre técnico y condiciones para avanzar de evidencia académica a piloto controlado.

CONCLUSIONES SUSTENTADAS

- 1. Accuracy aislada resulta engañosa en un evento con prevalencia cercana al 4%; el baseline obtuvo 96.16% sin detectar positivos.
- 2. Regresión Logística fue seleccionada por una ventaja consistente en PR-AUC frente a Random Forest y por su interpretabilidad.
- 3. El threshold 0.75 reduce la cartera priorizada a 11.10% del holdout y conserva recall de 75.64%.
- 4. El holdout alcanzó ROC-AUC 0.9248 y PR-AUC 0.3469; el comportamiento fue consistente con validación OOF.
- 5. La simulación A/B ilustra cómo medir impacto operacional, pero no constituye evidencia causal ni beneficio financiero real.

Decisión final | GO para piloto controlado; NO-GO para automatización

FinPredict cuenta con evidencia suficiente para pasar de validación académica a una prueba controlada en shadow/piloto. La producción automática debe esperar validación con datos reales, acuerdos de capacidad con Operaciones, monitoreo por segmentos, explicabilidad, seguridad y criterios de suspensión.

EVIDENCIAS VERIFICABLES

RECURSO	EVIDENCIA
notebooks/01_evaluacion_modelos_actividad6.ipynb	Baseline, CV temporal, bootstrap, threshold, holdout y A/B.
Data/	Datasets V2 de desarrollo y evaluación.
resultados/	CSV de comparación, threshold, holdout, A/B e impacto.
README.md	Descripción general y reproducibilidad del proyecto.

DECLARACIÓN DE IA GENERATIVA

Se utilizó ChatGPT como apoyo en estructuración y depuración de código, razonamiento metodológico, documentación del repositorio, análisis de resultados y redacción del informe. Las métricas y artefactos provienen de ejecuciones realizadas en Google Colab y fueron revisados por la autora.

REFERENCIAS Y MARCO DOCUMENTAL

- FinPredict. (2026). FinPredict - Actividad 6: repositorio técnico. GitHub. github.com/lizlorenzana931109-art/FinPredict-Actividad6
- scikit-learn developers. (s. f.). Model evaluation: quantifying the quality of predictions. scikit-learn.org
- National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0).